

# Коробов Евгений Владимирович

AI / LLM Engineer · агентные системы, RAG, Python

Ростов-на-Дону · удалённо, UTC+3 · в Ростове возможен гибрид или офис

+7 909 433-13-12 · [zakaz@p-don.ru](mailto:zakaz@p-don.ru) · [t.me/korobovevgen](https://t.me/korobovevgen)

[ai-producing.com](https://ai-producing.com) - полное резюме и проекты · [neiroaktiv.ru](https://neiroaktiv.ru)



## КОРОТКО

**Автоматизирую бизнес-процессы на Python и LLM: от постановки задачи до работающего сервиса на боевом сервере.** Два года пишу и сопровождаю продукты сам - бэкэнд, интеграции, диалоговые агенты, эксплуатация. До этого двадцать лет отвечал за процессы, которые теперь автоматизирую: контакт-центр на 350 человек, бэк-офис на 50 сотрудников с нуля, три собственные B2B-компании.

**Формат:** ищу полную занятость, удалённо. Операционное управление собственными компаниями передано, сохраняю за собой только владение. Готов выйти в течение двух недель.

## ЧТО ПОСТРОИЛ - С ССЫЛКАМИ, КОТОРЫЕ МОЖНО ОТКРЫТЬ

### AI-консультант в Telegram - @consultantbopor\_bot

Диалоговый продукт для платных консультаций: отвечает по корпусу знаний, помнит клиента между сессиями, готовит PDF-разбор, принимает оплату. Работает с 2025 года без остановок.

Что делал лично: всю систему - 622 модуля Python, поиск по базе знаний, диалоговый контур, платежи, административную панель. Сейчас на одном сервере под systemd работают 15 ботов, из них 12 - клиентские инсталляции этого продукта под разных консультантов, плюс три служебных API-сервиса. Эксплуатацию веду сам: обновления, разбор инцидентов, ротация ключей.

### Метеосервис для ветровых видов спорта - [vetrodozor.ru](https://vetrodozor.ru)

Публичный сервис: собирает прогнозы из нескольких независимых источников, приводит их к единой модели, считает показатели под конкретную дисциплину и присылает уведомление, когда условия совпали. Веб и мобильное приложение работают поверх одного ядра, есть платная подписка.

Что делал лично: backend на FastAPI и PostgreSQL с миграциями и фоновыми задачами, сбор и согласование данных из разных источников, расчётный слой, веб-интерфейс на React, мобильное приложение на React Native с push-уведомлениями, приём платежей, развёртывание и эксплуатация.

### Отказоустойчивость обращений к языковым моделям

Задача возникла из практики: сервис на одном поставщике встаёт целиком, когда тот отказывает или блокирует аккаунт. Сделал маршрутизацию между восемью поставщиками с приоритетами и автоматическим переключением по таймаутам и кодам ошибок. Настройки моделей лежат в базе, а не в коде, поэтому замена поставщика - изменение строки в базе, без выкладки новой версии.

Проверено на реальном отказе: основного поставщика заблокировали без предупреждения, сервисы продолжили работать на резервных моделях, простоя не было - о блокировке я узнал через три дня из письма.

### CRM для отдела продаж, multi-tenant

Собирала обращения из Avito и корпоративной почты в одну воронку, вела прайс-листы с ролевой наценкой, считала аналитику, выставляла счета в PDF с расчётом НДС. Несколько независимых аккаунтов в одной инсталляции с изоляцией данных.

Что делал лично: архитектуру и весь код - FastAPI, Next.js, PostgreSQL, Redis, Celery, развёртывание шестью контейнерами за nginx. Система работала в проде на отдельном домене; сейчас остановлена, показать могу код и запустить локально.

### Разбор проприетарного формата чертежей КОМПАС-3D

В собственной компании накопилась база из 2 000+ чертежей с дубликатами и устаревшими версиями, разобрать её вручную было нереально. Разобрал формат `.cdw` напрямую на Python без установленного КОМПАСа - оказался ZIP-контейнером со сжатыми потоками и строками в UTF-16. Поверх сделал аудит базы: поиск дубликатов, выбор актуальной версии по дате, перенос устаревших в карантин, пакетную правку штампов.

Результат: разовая ручная работа на несколько недель заменена процедурой на несколько минут.

### Внутренний учёт расхода и ключей

Свой контур: зашифрованное хранилище секретов со сроком ротации по каждому, сбор данных о расходе на модели с боевых серверов, сведение стоимости и выручки по проектам. Telegram-бот и веб-панель поверх одной базы.

Зачем: без этого расход на модели виден только постфактум в счетах, а стоимость проекта не сводится с его выручкой.

## ЧЕМ ЗАНИМАЮСЬ СЕЙЧАС

Маршрутизация запроса по намерению в диалоговых агентах: классификация по двум независимым осям - какой инструмент вызвать и в каком тоне отвечать. Плоский классификатор на таких задачах вынужден выбирать одно из двух и ошибаться на самых частых репликах. Состояние диалога хранится как элемент памяти, к которому агент возвращается сам.

Практический вывод, который лёг в основу: то, что вынесено в инструмент с проверяемым контрактом, начинает работать сразу; то, что осталось указанием в тексте промпта, конкурирует с десятками других правил и проигрывает. Поэтому сначала инструменты, потом классификатор поверх них.

**Про фреймворки прямо:** RAG и агентов собирал без LangChain и LlamaIndex - на ChromaDB и sentence-transformers напрямую. Понимаю, что фреймворк делает внутри: разбиение на фрагменты, поиск, сборку контекста, вызов инструментов. Опыт работы с самими фреймворками указываю отдельно, чтобы не вводить в заблуждение.

## СТЕК

**Python** · FastAPI, Pydantic, asyncio, SQLAlchemy, Alembic, Celery, APScheduler, httpx, aiohttp, pytest

**LLM** · Anthropic SDK, Google GenAI / Vertex AI, OpenAI, Groq, Cerebras, DeepSeek, OpenRouter, Ollama; проектирование промптов и агентных протоколов, собственный слой вызова инструментов, контроль расхода и стоимости токенов

**RAG и векторный поиск** · ChromaDB, sentence-transformers, multilingual-e5, стратегии чанкинга и перекрытия, инкрементальная переиндексация, метаданные и фильтры

**Данные** · PostgreSQL (psycopg, asyncpg), Redis, SQLite

**Инфраструктура** · Linux, Docker, Docker Compose, nginx, systemd, деплой скриптами по SSH, Cloudflare, DigitalOcean, Яндекс.Облако; мониторинг - systemd, логи, алерты в Telegram, Flower, экспорт метрик Prometheus из приложения

**Telegram** · aiogram, python-telegram-bot, Pyrogram - боты, платежи, вебхуки, голосовой ввод

**ML и медиа** · Whisper STT, PyTorch, HuggingFace Transformers, Stable Diffusion, Pillow, FFmpeg, numpy, pandas

**Frontend** · React, Next.js 14, TypeScript, Tailwind; мобильное - React Native, Expo

**Автоматизация** · Playwright, BeautifulSoup, Selenium

## ОПЫТ

**НейроАктив - основатель, AI-инженер**

**2025 - настоящее время · AI-автоматизация для малого и среднего бизнеса · удалённо**

- **B2B SaaS CRM для отделов продаж** в проде на отдельном домене с SSL: лиды из Avito и корпоративной почты в единую воронку, прайс-листы с ролевой логикой наценки, аналитика продаж, AI-бот, панель суперадминистратора. Multi-tenant с изоляцией данных по аккаунтам, двухуровневые правила фильтрации почты, денормализация горячих полей под быструю выдачу, генерация счетов в PDF с расчётом НДС. FastAPI + Next.js 14 + PostgreSQL + Redis, Docker Compose, nginx
- **AI-консультант в проде:** 622 модуля Python, 135 000 строк. Диалоговый контур с долговременной памятью, RAG-поиск по корпусу, генерация PDF-отчётов, приём платежей
- **Агенты, забирающие функции целиком:** подготовка ответов на требования и проверки налоговой; ведение юридического контура компании - договоры, претензии, процессуальные документы, сопровождение арбитражных и гражданских дел
- **Аналитический погодный хаб:** агрегация прогнозов из независимых источников, приведение к единой модели, расчёт производных показателей, графики и алерты. Веб и мобильное приложение поверх одного ядра. FastAPI + PostgreSQL + Alembic + Celery, React, React Native + Expo, Firebase push
- **Подписочный сервис с биллингом:** парк серверных узлов, автоматическая выдача и отзыв доступов, идемпотентная обработка платёжных уведомлений, редакторский контур на LLM с автопостингом
- **Обратная разработка проприетарного формата чертежей КОМПАС-3D:** разбор `.cdw` напрямую на Python без установленного КОМПАСа - ZIP-контейнер, многопоточный zlib, UTF-16. Аудит и дедупликация базы на 2 000+ единиц, пакетная правка штампов
- **Эксплуатация 6+ боевых серверов:** провижининг, systemd-юниты, nginx, деплой по SSH, мониторинг, ротация секретов, разбор инцидентов

**Двадцать лет до этого - управление процессами и данными**

**Tele2, руководитель контакт-центра (2006-2012).** Путь от оператора до руководителя 350 подчинённых; обслуживание 28 регионов круглосуточно. Управление строилось на цифрах: анализ показателей, отслеживание просадок в реальном времени, прогнозирование входящего трафика, отчётность с дискретностью 15 минут, real-time визуализация показателей в операторских залах. Отток персонала снижен с 7,5% до 1,2% в месяц, время обслуживания - с 120 до 100 секунд. Отдельно построил с нуля бэк-офис на 50 человек: письменные претензии абонентов 36 регионов, удовлетворённость решением с 65% до 85%.

**Ростелеком (2015-2016).** Абонентский отток нормализован до целевых показателей за полгода. Централизация архивов из 50+ населённых пунктов.

**Собственные B2B-компании (2016 - настоящее время):** СтройЮгКомплект, ЭКОРЕСУРС, ПОСЕЙДОН. Все бизнес-процессы с нуля. Оборот до 30 млн ₽ в год, сделок на 150+ млн ₽, база 1 500 активных клиентов. Собственная CRM, онлайн-просчёт заказа в момент звонка, маркетинг и вёрстка своими силами.

## ОБРАЗОВАНИЕ

**Южный федеральный университет** - химик, специальность «Химия», специализация «Коллоидная химия», 2004-2010. Расчётная часть программы: математика 680 часов, **численные методы и программирование**, квантовая механика и квантовая химия, кристаллохимия, строение вещества. Плюс квалификация преподавателя, дополнительное к высшему, 2005-2010, 1 400 часов.

**ДГТУ** - аспирантура, не окончена. «Управление в стиле коучинг» 2011 · немецкий B1.

*Готов к техническому интервью с разбором любого проекта: архитектура, код, деплой, инциденты в проде и как они разбирались.*